

README — Fraud Detection System

Progetto Jemib per il rilevamento di transazioni fraudolente mediante Machine Learning

Descrizione del progetto

Questo notebook implementa una pipeline end-to-end di classificazione binaria per il rilevamento di frodi su transazioni di pagamento. Il flusso comprende: unione di due dataset, pulizia (duplicati e missing values), analisi esplorativa (univariata, bivariata, multivariata), gestione dello sbilanciamento delle classi (undersampling + SMOTE), addestramento e confronto di 4 modelli (Logistic Regression, Decision Tree, Random Forest, XGBoost), ottimizzazione con GridSearchCV e analisi della feature importance.

Requisiti

Python 3.8+ | Jupyter Notebook o JupyterLab | I dataset `SH.DataSet(3).csv` e `SHDATA2(1).csv` nella stessa cartella del notebook.

Installazione delle dipendenze

```
pip install pandas numpy matplotlib seaborn scipy scikit-learn imbalanced-learn xgboost
```

Come eseguire il notebook

1. Posizionare i file CSV nella stessa directory del notebook .ipynb
2. Aprire un terminale e lanciare: `jupyter notebook` (oppure `jupyter lab`)
3. Nel browser, navigare al file e aprirlo
4. Eseguire tutte le celle in ordine: menu **Kernel > Restart & Run All** oppure `Shift+Enter` cella per cella
5. I risultati (grafici, tabelle, metriche) vengono mostrati inline sotto ogni cella

Struttura del notebook

Sezione	Contenuto
1. Import e preparazione	Caricamento CSV, unione dataset, rimozione duplicati e missing values
2. Analisi univariata	Distribuzione di ogni variabile (bar chart, boxplot, istogrammi)
3. Analisi bivariata	Kruskal-Wallis (numeriche vs Fraud), Chi-Quadro (categoriche vs Fraud)
4. Analisi multivariata	Heatmap di Cramér, Pearson, Spearman; gestione multicollinearità
5. Bilanciamento classi	Undersampling classe 0 (70%) + SMOTE sul training set
6. Modellazione	LogReg, Decision Tree, Random Forest, XGBoost — 5 split ripetuti
7. Ottimizzazione	GridSearchCV con recall classe 1 come metrica
8. Interpretabilità	Feature importance del modello finale (Decision Tree)

Output principale

Il modello finale è un **Decision Tree ottimizzato** con accuracy media del **95,0%** su 5 split di validazione. Le variabili più rilevanti risultano: `amount`, `paymentmethod`, `risk_score` e `product`.

Note

- L'esecuzione completa richiede circa 10–15 minuti (la GridSearchCV di XGBoost è la parte più pesante).
- Il notebook è progettato per essere eseguito in ordine sequenziale: ogni cella dipende dalle precedenti.
- I warning di scikit-learn sulle feature names sono attesi e non influenzano i risultati.