

Sistema di Rilevamento Frodi su Transazioni di Pagamento

Progetto svolto per un cliente della Junior Enterprise
durante l'esperienza universitaria in Junior Enterprise

Nota sulla privacy e sulla pubblicazione. Il progetto descritto in questo report è stato realizzato durante la mia partecipazione a una Junior Enterprise universitaria, per conto di un cliente reale operante nel settore dei pagamenti digitali. Poiché la Junior Enterprise opera sotto vincoli di riservatezza nei confronti dei propri clienti, ai fini della pubblicazione di questo progetto nel mio portfolio personale sono stati **volutamente omessi tutti i dati sensibili**: il nome del cliente e ogni riferimento identificativo non compaiono in questo documento; nel notebook associato le osservazioni reali del dataset non vengono mostrate in output (viene riportata unicamente la dimensione del dataset); i nomi delle categorie delle variabili qualitative sono stati sostituiti con etichette generiche (*Metodo_1*, *Stato_1*, *Modulo_1*, *Prodotto_1*, ...).

I nomi delle variabili (colonne) sono stati lasciati inalterati perché il preprocessing dei dati grezzi è stato svolto direttamente dal sottoscritto e le intestazioni delle colonne non contengono informazioni riconducibili al cliente. Tutti i risultati statistici, i test e le metriche riportati qui di seguito sono **quelli reali** del progetto: l'anonimizzazione delle categorie è biunivoca e non altera in alcun modo l'analisi.

1. Contesto e obiettivo del progetto

Il cliente era chiamato a gestire quotidianamente un volume elevato di transazioni di pagamento, tra le quali una piccola frazione (meno del 3%) risultava fraudolenta. La revisione manuale di ogni transazione non era sostenibile, e la rarità dei casi di frode rendeva particolarmente difficile per un sistema automatico apprendere a distinguerli da quelli legittimi.

L'obiettivo è stato costruire un modello di Machine Learning in grado di classificare automaticamente le transazioni come **fraudolente** o **legittime**, restituendo al cliente uno strumento interpretabile e utilizzabile in produzione per identificare tempestivamente i pagamenti sospetti.

2. Raccolta e preparazione dei dati

Il cliente ha fornito due dataset. Il primo (4614 transazioni, 7 variabili) presentava un forte sbilanciamento della variabile target **Fraud**: circa il 98% delle transazioni era legittimo e solo il 2% fraudolento. Il secondo dataset conteneva le stesse colonne del primo; da esso sono state estratte le sole **11 transazioni fraudolente** presenti, al fine di aumentare la rappresentatività della classe minoritaria. I due contributi sono stati concatenati, producendo un dataset unificato di **4625 righe**.

2.1 Struttura del dataset

Variabile	Tipo	Descrizione
Fraud	binaria (0/1)	Target: 1 = frode, 0 = legittima
amount	numerica	Importo della transazione
risk_score	numerica	Punteggio di rischio della transazione
paymentmethod	categorica	Metodo di pagamento utilizzato
status	categorica	Stato della transazione
fraudmodule	categorica	Modulo di rilevamento frodi impiegato
product	categorica	Prodotto/servizio oggetto della transazione

2.2 Rimozione dei duplicati

Un'analisi preliminare ha evidenziato **1516 righe duplicate**. La loro rimozione ha portato il dataset a **3109 righe** e ha ridotto il conteggio delle frodi da 98 a **85**. La riduzione delle frodi in fase di deduplica è un dato importante: significa che una parte delle poche osservazioni positive era ridondante e non avrebbe contribuito ad arricchire il segnale di apprendimento del modello.

2.3 Valori mancanti

L'analisi dei valori mancanti ha restituito un quadro sostanzialmente pulito: l'unica variabile con missing rilevanti è **product** (1,93%), un livello ritenuto accettabile che non ha richiesto strategie di imputazione. Le mancanze in **fraudmodule** (0,03%) sono trascurabili e diventano irrilevanti dopo la rimozione della variabile stessa.

3. Analisi esplorativa dei dati (EDA)

L'analisi esplorativa è stata condotta a tre livelli progressivi (univariata, bivariata, multivariata) con l'obiettivo di comprendere la distribuzione di ciascuna variabile, quantificarne l'associazione con la variabile target **Fraud** e individuare eventuali fenomeni di multicollinearità che avrebbero potuto influenzare negativamente la modellazione.

3.1 Analisi univariata

Fraud (target). Fortemente sbilanciata: circa il 97% dei casi appartiene alla classe legittima e solo il 3% alla classe frode. Questo squilibrio è il vincolo dominante di tutto il progetto ed è stato affrontato in modo esplicito nella fase di modellazione.




Figura 1 — Distribuzione della variabile target Fraud.

status. Distribuzione fortemente concentrata: una categoria da sola raccoglie il 63% delle osservazioni, una seconda circa il 26%, una terza l'11%, mentre l'ultima è sostanzialmente trascurabile.




Figura 2 — Distribuzione della variabile status (etichette anonimizzate).

fraudmodule. La variabile assume quasi esclusivamente un unico valore, con una variante presente in rarissimi casi. Data la variabilità pressoché nulla, è stata **giudicata non informativa e rimossa dal dataset**: una feature quasi costante non fornisce segnale utile a un classificatore.




Figura 3 — Distribuzione di fraudmodule (quasi costante, etichette anonimizzate).

amount. Distribuzione fortemente asimmetrica, con predominanza di importi piccoli e una lunga coda destra. Il boxplot evidenzia la presenza di **549 outlier** nella coda superiore. Data la natura del dominio (transazioni di pagamento), gli outlier non sono stati rimossi: importi anomali possono di per sé essere un segnale predittivo di frode.




Figura 4 — Boxplot della variabile amount: si osserva la presenza di outlier nella coda superiore.




Figura 5 — Istogramma con funzione di densità di amount: distribuzione fortemente asimmetrica a destra.

paymentmethod. Cinque modalità con distribuzione eterogenea: due categorie dominano il campione (una circa 48%, una 35%), le rimanenti tre pesano tra il 3% e il 7%.




Figura 6 — Distribuzione della variabile paymentmethod (etichette anonimizzate).

product. Cardinalità elevata: 56 categorie distinte. La distribuzione è fortemente concentrata su pochi prodotti principali seguiti da una lunga coda. La cardinalità è un elemento da tenere presente in fase di encoding e di modellazione, perché favorisce l'overfitting su categorie rare.




Figura 7 — Distribuzione della variabile product (etichette anonimizzate, coda lunga).

3.2 Analisi bivariata

L'obiettivo è stato quantificare l'associazione tra ogni variabile indipendente e la variabile target, scegliendo test statistici appropriati alla natura delle variabili.

Variabili numeriche vs Fraud — Test di Kruskal-Wallis. Test non parametrico che confronta la distribuzione di una variabile numerica tra due o più gruppi basandosi sui ranghi. È stata affiancata la stima della dimensione dell'effetto tramite Epsilon Squared (ϵ^2).

Variabile	Statistica H	p-value	Epsilon Squared
risk_score	15,68	0,0001	0,0047 (0,47%)
amount	132,80	< 0,0001	0,0424 (4,24%)

Entrambe le variabili mostrano un'associazione **statisticamente significativa** con Fraud, ma la dimensione dell'effetto è piccola in entrambi i casi. Il p-value indica *che* esiste un'associazione; ϵ^2 indica *quanto* è *forte*: nessuna delle due, da sola, spiega una porzione consistente della varianza di Fraud.

Variabili categoriche vs Fraud — Test del Chi-Quadro.

Variabile	Statistica χ^2	p-value	Gradi di libertà
status	9327	< 0,0001	9
product	2403	< 0,0001	168
paymentmethod	1277	< 0,0001	12

Tutte e tre le variabili risultano fortemente associate al target. Va tenuto presente che il χ^2 cresce con il numero di gradi di libertà, quindi la posizione dominante di **status** è particolarmente notevole (χ^2 molto elevato con soli 9 gradi di libertà).

3.3 Analisi multivariata

Sono state costruite tre mappe di calore di correlazione, ciascuna appropriata a un diverso tipo di variabile.

Cramér's V — misura l'associazione tra variabili categoriche su una scala da 0 (nessuna associazione) a 1 (associazione perfetta).




Figura 8 — Mappa di calore di Cramér's V per le variabili categoriche.

Pearson — misura la correlazione *lineare* tra variabili numeriche (e categoriche codificate); appropriato dove il concetto di distanza numerica è ben definito.




Figura 9 — Mappa di calore di Pearson (tutte le variabili codificate).

Spearman — basata sui ranghi, non richiede l'assunzione di linearità e può essere applicata sia a variabili numeriche sia a variabili categoriche codificate.




Figura 10 — Mappa di calore di Spearman: si nota la forte correlazione (0,74) tra status e amount.

Verifica formale con test di Spearman. Per le variabili numeriche che mostravano una correlazione bassa con Fraud, è stato eseguito un test formale.

Coppia	Spearman ρ	p-value	Significativa?
Fraud vs amount	0,207	< 0,0001	Sì
Fraud vs risk_score	0,071	0,0001	Sì

Entrambe le correlazioni risultano statisticamente significative, giustificando la scelta di mantenere queste variabili nel modello nonostante la magnitudo modesta.

Gestione della multicollinearità. L'analisi ha evidenziato una **correlazione molto forte tra status e amount** (Spearman $\rho = 0,737$, $p < 0,0001$). Questo livello configura un rischio concreto di multicollinearità: mantenere entrambe le variabili avrebbe portato i modelli a dividersi il segnale predittivo tra due feature ridondanti, rendendo instabili i coefficienti e complicando l'interpretazione. La scelta è stata di **rimuovere status** e mantenere amount, sia perché più direttamente legata alla natura economica della transazione, sia perché mostrava un'associazione con Fraud di livello confrontabile.

3.4 Riepilogo delle variabili dopo la fase esplorativa

Variabile	Ruolo	Motivazione
Fraud	target	Variabile da predire
amount	feature	Correlazione significativa con Fraud
risk_score	feature	Correlazione significativa con Fraud
paymentmethod	feature	Associazione significativa ($\chi^2 = 1277$)
product	feature	Associazione significativa ($\chi^2 = 2403$)

Rimosse: fraudmodule (variabilità quasi nulla, non informativa) e status (multicollinearità con amount).

4. Gestione dello sbilanciamento delle classi

Con una classe minoritaria intorno al 3%, un modello che predice sempre la classe maggioritaria otterrebbe un'accuracy del 97% pur fallendo completamente il proprio scopo (riconoscere le frodi). Per questo la gestione dello sbilanciamento è stata affrontata in modo esplicito con una strategia a due fasi.

Fase 1 — Undersampling della classe maggioritaria. Le transazioni legittime sono state sottocampionate al 70%: il loro numero è passato da circa 3024 a circa 2117 osservazioni. Le 85 transazioni fraudolente sono state mantenute integralmente. Il dataset risultante contiene **2202 righe**.

Fase 2 — SMOTE sul solo training set. SMOTE (Synthetic Minority Over-sampling Technique) genera nuove osservazioni della classe minoritaria interpolando tra osservazioni esistenti nello spazio delle feature. È stato applicato con *sampling_strategy* tra 0,8 e 0,9 a seconda del modello.

Nota critica sul data leakage. SMOTE è stato applicato **esclusivamente dopo la separazione tra training set e test set**, e solo sul training set. Applicare SMOTE prima dello split avrebbe generato osservazioni sintetiche a partire da record che sarebbero poi finiti nel test set, contaminando la valutazione con informazioni provenienti dal test stesso.




Figura 11 — Distribuzione di Fraud dopo l'undersampling (prima dell'applicazione di SMOTE).

5. Costruzione e valutazione dei modelli predittivi

Data la limitata numerosità del dataset e la ridotta dimensionalità delle feature, sono stati preferiti algoritmi relativamente semplici e interpretabili, escludendo approcci troppo complessi (es. reti neurali) che avrebbero rischiato l'overfitting su un dataset di poche migliaia di righe.

5.1 Strategia di validazione

Per ottenere una stima delle performance **robusta** e non dipendente da un singolo split, la validazione è stata ripetuta su **5 split indipendenti** (random state da 1 a 5). Per ciascuno split sono state selezionate casualmente **26 osservazioni per ciascuna classe** come test set (52 osservazioni totali), mantenendo il resto come training set. SMOTE è stato applicato solo al training set e l'accuracy è stata mediata sui 5 split.

Costruire un test set **bilanciato** con lo stesso numero di frodi e legittime è una scelta consapevole: consente di leggere l'accuracy come una metrica onesta (in un test bilanciato al 50/50, un classificatore banale che predice sempre una classe si ferma al 50%), evitando l'illusione tipica dei dataset molto sbilanciati.

5.2 Modelli testati (configurazione iniziale)

Modello	Configurazione principale
Regressione Logistica	C = 0,8; solver LBFGS; class_weight = {0:1, 1:2}; StandardScaler
Decision Tree	max_depth = 6; min_samples_split = 8
Random Forest	n_estimators = 30; max_depth = 6; min_samples_split = 10
XGBoost	30 alberi; max_depth = 4; lr = 0,1; subsample = 0,7

5.3 Risultati della configurazione iniziale

Modello	RS=1	RS=2	RS=3	RS=4	RS=5	Media
Regressione Logistica	69,2%	73,1%	76,9%	82,7%	78,8%	76,2%
Decision Tree	84,6%	88,5%	84,6%	86,5%	92,3%	87,3%
Random Forest	82,7%	90,4%	86,5%	94,2%	92,3%	89,2%
XGBoost	76,9%	90,4%	86,5%	92,3%	96,2%	88,5%

I modelli ad albero superano significativamente la Regressione Logistica, coerentemente con il fatto che la relazione tra le feature e la target non è puramente lineare. In configurazione iniziale, la Random Forest ottiene l'accuracy media più alta (89,2%).

6. Ottimizzazione degli iperparametri

Per migliorare le performance è stata condotta una ricerca sistematica degli iperparametri ottimali tramite **GridSearchCV con cross-validation a 5 fold**.

6.1 Scelta della metrica di ottimizzazione

Nel contesto del rilevamento frodi, gli errori non sono simmetrici: un **falso negativo** (una frode classificata come legittima) è tipicamente molto più costoso di un falso positivo (una transazione legittima segnalata come sospetta, che può essere gestita con un controllo aggiuntivo). Per questo motivo la metrica scelta per l'ottimizzazione non è stata l'accuracy, bensì il **recall della classe positiva** (Fraud = 1), ovvero la percentuale di frodi effettivamente identificate dal modello.

6.2 Griglie di ricerca

Modello	Iperparametri esplorati
Regressione Logistica	C ∈ {0,1; 0,5; 0,8; 1; 5}; fit_intercept; max_iter ∈ {100, 200, 300}
Decision Tree	max_depth ∈ {8,10,12,14,16}; min_samples_split ∈ {2,4,8,16}; criterion ∈ {gini, entropy}; min_samples_leaf ∈ {1,2,4}

Random Forest	<code>n_estimators</code> ∈ {15,30,50,100}; <code>max_depth</code> ∈ {4,6,8,10,12}; <code>min_samples_split</code> ; <code>criterion</code> ; <code>min_samples_leaf</code>
XGBoost	griglia ampia (~1620 combinazioni): <code>n_estimators</code> , <code>max_depth</code> , <code>learning_rate</code> , <code>subsample</code> , <code>colsample_bytree</code> , <code>scale_pos_weight</code>

6.3 Risultati dopo l'ottimizzazione

Modello	RS=1	RS=2	RS=3	RS=4	RS=5	Media
Regressione Logistica (tuned)	71,2%	75,0%	78,8%	84,6%	80,8%	78,1%
Decision Tree (tuned)	94,2%	92,3%	92,3%	96,2%	100%	95,0%
Random Forest (tuned)	82,7%	90,4%	90,4%	94,2%	94,2%	90,4%
XGBoost (tuned)	50,0%	50,0%	50,0%	50,0%	50,0%	50,0%

6.4 Lettura dei risultati

Decision Tree (tuned) — Modello con la migliore performance. Con un'accuracy media del **95,0%** e un picco del 100% sul quinto split, ottiene un miglioramento di **+8 punti percentuali** rispetto alla configurazione iniziale.

Random Forest (tuned). Miglioramento marginale (da 89,2% a 90,4%): la versione ottimizzata conferma la solidità del modello, ma il guadagno dall'ottimizzazione è modesto perché la configurazione iniziale era già ragionevole.

Regressione Logistica (tuned). Miglioramento contenuto (da 76,2% a 78,1%), coerente con la natura lineare del modello: l'assunzione di linearità è il vero limite, e nessun tuning degli iperparametri lo aggira.

XGBoost (tuned) — Il collasso e cosa insegna. Dopo l'ottimizzazione, XGBoost degenera al 50% di accuracy su tutti gli split, un valore compatibile con un modello che classifica *tutto* come frode (in un test set bilanciato al 50/50, ciò porta esattamente al 50% di accuracy). Il fenomeno è attribuibile alla combinazione tra la **griglia molto ampia** (~1620 combinazioni) e la **metrica di ottimizzazione** (recall della classe positiva): con abbastanza combinazioni da esplorare, la GridSearch ha trovato una configurazione che **massimizza il recall triviale** (recall = 100% se predici sempre 1) al costo di una precision degenerare. È un caso di scuola su cui vale la pena soffermarsi: ottimizzare una singola metrica su un dataset piccolo, senza vincoli aggiuntivi sulla precision o senza usare metriche composite (es. F1, AUC), può portare l'algoritmo a scoprire «soluzioni patologiche» che soddisfano il criterio ma non l'obiettivo di business.

7. Modello finale e interpretabilità

7.1 Modello selezionato

Il modello selezionato come soluzione finale è il **Decision Tree ottimizzato**, per due ragioni: (i) **performance predittiva** — 95,0% di accuracy media su 5 split di validazione bilanciati, la migliore tra i modelli testati; (ii) **interpretabilità** — un albero decisionale è ispezionabile: ogni predizione può essere ricondotta a un percorso di regole leggibili sulle feature. In ambito fraud detection

questo è un vantaggio operativo non secondario, perché consente al cliente di **giustificare** le segnalazioni prodotte dal modello sia internamente sia, se necessario, davanti al cliente finale della piattaforma di pagamento.




Figura 12 — Curva ROC del Decision Tree ottimizzato (split RS=1): AUC = 0,99.

7.2 Feature Importance

L'analisi della feature importance del Decision Tree finale — che misura il contributo di ciascuna variabile alla riduzione dell'impurità di Gini all'interno dell'albero — restituisce l'ordinamento mostrato in Figura 13:

1. **amount** — contributo dominante (~0,58). L'importo della transazione è di gran lunga la variabile più predittiva.
2. **paymentmethod** — contributo intermedio (~0,17).
3. **risk_score** — contributo intermedio (~0,15).
4. **product** — contributo minore (~0,08).




Figura 13 — Feature importance del Decision Tree ottimizzato.

La centralità di **amount** è coerente con quanto emerso dall'analisi bivariata (test di Kruskal-Wallis, correlazione di Spearman) e conferma che la dimensione economica della transazione è il driver

principale del comportamento del modello.

8. Riepilogo della pipeline

Fase	Azione	Dettaglio
1. Dati	Unione dei due dataset	Dataset 1 + 11 frodi dal Dataset 2 → 4625 righe
2. Pulizia	Rimozione duplicati	1516 duplicati rimossi → 3109 righe, 85 frodi
3. Feature selection	Rimozione variabili	Rimosse fraudmodule (quasi costante) e status (multicollinearità con amount)
4. Encoding	Label encoding	Codifica numerica di paymentmethod, product, status
5. Bilanciamento	Undersampling + SMOTE	Undersampling al 70% sulla classe 0; SMOTE solo sul training set
6. Modellazione	4 algoritmi	Logistic Regression, Decision Tree, Random Forest, XGBoost
7. Validazione	5 split ripetuti	26 obs/classe nel test; accuracy media come metrica di sintesi
8. Ottimizzazione	Grid Search CV	Recall classe 1 come metrica; 5-fold CV
9. Risultato	Decision Tree ottimizzato	Accuracy media 95,0% — modello selezionato

9. Conclusioni

Il progetto ha dimostrato la fattibilità di un sistema di rilevamento automatico delle frodi basato su tecniche di Machine Learning anche in presenza di un dataset di dimensioni contenute e fortemente sbilanciato. Il **Decision Tree ottimizzato**, con un'accuracy media del 95,0% su 5 split di validazione bilanciati, rappresenta il modello con le migliori performance e, grazie alla sua natura interpretabile, si presta particolarmente all'impiego in contesti operativi in cui è necessario giustificare le decisioni del sistema.

Lezioni operative

- Le variabili più rilevanti per la classificazione delle frodi sono **amount**, **paymentmethod**, **risk_score** e **product**, con un ruolo dominante dell'importo della transazione.
- Lo sbilanciamento delle classi è stato gestito con successo grazie a una combinazione di undersampling della classe maggioritaria e SMOTE della minoritaria, applicato correttamente solo al training set per evitare data leakage in fase di valutazione.
- L'ottimizzazione degli iperparametri ha prodotto un miglioramento sostanziale sul Decision Tree (+8 punti percentuali) ma ha anche esposto il rischio dell'ottimizzazione unidimensionale su dataset piccoli: il collasso di XGBoost è un caso di scuola sul perché non ci si debba affidare a una singola metrica quando la griglia di ricerca è ampia.

Sviluppi futuri

Con dati aggiuntivi provenienti da periodi successivi, sarebbe possibile: arricchire il dataset per migliorare la robustezza del modello; sperimentare tecniche di feature engineering più avanzate (aggregazioni temporali, frequenza per utente/prodotto); riprovare XGBoost con una metrica composita come F1 o AUC al posto del recall puro; e valutare metriche di business più significative

dell'accuracy, come il costo atteso degli errori pesato sull'impatto economico delle frodi non intercettate.

Report redatto a corredo del progetto svolto durante la partecipazione a una Junior Enterprise universitaria. Il notebook associato (Notebook_Fraud_Detection_anonimizzato.ipynb) applica le stesse misure di privacy descritte nella nota introduttiva.