

REPORT DI PROGETTO

Sistema di Rilevamento Frodi su Transazioni di Pagamento

Analisi Esplorativa, Modellazione Predittiva e Ottimizzazione

Realizzato da: Jemib — Junior Enterprise Milano-Bicocca
Per: Volutamente omesso per questioni di privacy

Indice

Indice.....	2
1. Introduzione.....	4
2. Raccolta e Preparazione dei Dati	5
2.1 Fonti dei dati	5
2.2 Struttura del dataset	5
2.3 Gestione dei duplicati.....	5
2.4 Valori mancanti.....	5
3. Analisi Esplorativa dei Dati (EDA).....	7
3.1 Analisi univariata	7
Variabile “Fraud” (target).....	7
Variabile “status”.....	7
Variabile “fraudmodule”	8
Variabile “amount”.....	8
Variabile “paymentmethod”	9
Variabile “product”	10
3.2 Analisi bivariata	11
3.2.1 Variabili numeriche vs. Fraud: Test di Kruskal-Wallis	11
3.2.2 Variabili categoriche vs. Fraud: Test del Chi-Quadro	11
3.3 Analisi multivariata.....	12
Mappa di calore di Cramér’s V	12
Mappa di calore di Pearson.....	12
Mappa di calore di Spearman	13
Verifica della significatività con il test di Spearman	13
Gestione della multicollinearità.....	14
3.4 Riepilogo delle variabili dopo la fase esplorativa	14
4. Gestione dello Sbilanciamento delle Classi	15
4.1 Strategia: undersampling + SMOTE	15
5. Costruzione e Valutazione dei Modelli Predittivi	16
5.1 Strategia di validazione	16
5.2 Modelli testati (configurazione iniziale)	16
5.2.1 Regressione Logistica.....	16
5.2.2 Decision Tree	16
5.2.3 Random Forest.....	16
5.2.4 XGBoost	16
5.3 Risultati della configurazione iniziale	16
6. Ottimizzazione degli Iperparametri	19
6.1 Metrica di ottimizzazione.....	19
6.2 Griglie di ricerca	19

Regressione Logistica.....	19
Decision Tree	19
Random Forest.....	19
XGBoost.....	19
6.3 Risultati dopo l'ottimizzazione.....	19
Analisi dei risultati	20
7. Modello Finale e Interpretabilità	21
7.1 Modello selezionato: Decision Tree ottimizzato	21
7.2 Feature Importance	21
8. Riepilogo della Pipeline	22
9. Conclusioni e Considerazioni Finali	23

1. Introduzione

Il presente report descrive nel dettaglio il progetto di sviluppo di un sistema di rilevamento automatico delle frodi su transazioni di pagamento, commissionato alla Junior Enterprise Jemib dell'Università degli Studi di Milano-Bicocca. L'obiettivo principale del progetto è stato quello di costruire un modello di Machine Learning in grado di classificare le transazioni come fraudolente o legittime, a partire dai dati storici forniti dal cliente.

Il documento è organizzato in modo da ripercorrere l'intero ciclo di vita del progetto: dalla raccolta e preparazione dei dati, all'analisi esplorativa, fino alla costruzione, valutazione e ottimizzazione dei modelli predittivi. Ogni decisione metodologica viene motivata e commentata affinché il lettore possa comprendere appieno la logica seguita.

2. Raccolta e Preparazione dei Dati

2.1 Fonti dei dati

Il progetto si è basato su due dataset distinti forniti dal cliente:

Dataset originale (SH.DataSet): contenente 4614 transazioni con 7 variabili. Questo dataset presentava un forte sbilanciamento nella variabile target “Fraud”: circa il 98% delle transazioni erano legittime (Fraud = 0) e solo il 2% fraudolente (Fraud = 1).

Dataset aggiuntivo (SHDATA2): un secondo dataset con le medesime colonne, dal quale sono state estratte le sole 11 transazioni fraudolente (Fraud = 1), al fine di incrementare la rappresentatività della classe minoritaria.

I due dataset sono stati concatenati, producendo un dataset unificato di 4.625 righe.

2.2 Struttura del dataset

Il dataset risultante contiene le seguenti 7 variabili:

Variable	Tipo	Descrizione
Fraud	Binaria (0/1)	Variabile target: 1 = frode, 0 = legittima
amount	Numerica continua	Importo della transazione
risk_score	Numerica continua	Punteggio di rischio associato alla transazione
paymentmethod	Categorica	Metodo di pagamento utilizzato
status	Categorica	Stato della transazione (Active, Pending, Fraud, Cancelled)
fraudmodule	Categorica	Modulo di rilevamento frodi (es. Maxmind, SKIPPED)
product	Categorica	Prodotto o servizio acquistato

2.3 Gestione dei duplicati

Un’analisi preliminare ha rivelato la presenza di 1.516 righe duplicate nel dataset unificato. Queste sono state rimosse, riducendo il dataset a 3.109 righe. Il numero di transazioni fraudolente è passato da 98 a 85 dopo la rimozione dei duplicati.

Metrica	Prima della rimozione	Dopo la rimozione
Numero totale di righe	4.625	3.109
Transazioni fraudolente	98	85
Duplicati rimossi	—	1.516

2.4 Valori mancanti

L’analisi dei valori mancanti ha evidenziato una situazione complessivamente positiva: la quasi totalità delle variabili è completa. L’unica eccezione rilevante è la variabile “product”, con l’1,93% di valori mancanti, un livello ritenuto accettabile e che non ha richiesto interventi di imputazione.

Variable	% valori mancanti
Fraud	0,00%
amount	0,00%
paymentmethod	0,00%
status	0,00%

Variabile	% valori mancanti
fraudmodule	0,03%
risk_score	0,00%
product	1,93%

3. Analisi Esplorativa dei Dati (EDA)

L'analisi esplorativa è stata condotta a tre livelli progressivi di profondità: univariata, bivariata e multivariata. L'obiettivo è stato comprendere la distribuzione di ciascuna variabile, identificare le relazioni con la variabile target "Fraud" e individuare eventuali problemi di multicollinearità.

3.1 Analisi univariata

Variabile "Fraud" (target)

La variabile target risulta fortemente sbilanciata: la classe 0 (transazione legittima) rappresenta la stragrande maggioranza delle osservazioni, mentre la classe 1 (frode) costituisce solo una piccola frazione. Questo sbilanciamento è un aspetto critico che è stato affrontato in fase di modellazione.




Figura 1 — Distribuzione della variabile target "Fraud"

Variabile "status"

La categoria "Pending" rappresenta la maggior parte dei dati con una frequenza relativa del 63%. La seconda categoria più comune è "Active" (circa 26%), mentre la categoria "Fraud" è presente solo nell'11% dei casi. La frequenza per "Cancelled" è trascurabile.




Figura 2 — Distribuzione della variabile "status"

Variabile "fraudmodule"

Questa variabile assume quasi esclusivamente un unico valore ("Maxmind"), con una variante "SKIPPED" presente in rarissimi casi. Data la bassissima variabilità, la variabile è stata giudicata non informativa e rimossa dal dataset.






Figura 3 — Distribuzione della variabile "fraudmodule" (quasi costante)

Variabile "amount"

La distribuzione dell'importo delle transazioni evidenzia una forte predominanza di valori piccoli, con pochi casi con importi molto elevati. Il boxplot conferma la presenza di numerosi outlier nella coda superiore della distribuzione.

*Figura 4 — Boxplot della variabile "amount"**Figura 5 — Istogramma con funzione di densità di "amount"*

Variabile "paymentmethod"

La variabile presenta diverse modalità di pagamento, con una distribuzione eterogenea.




Figura 6 — Distribuzione della variabile “paymentmethod”

Variable “product”

La variabile “product” presenta un elevato numero di modalità distinte. La distribuzione è fortemente concentrata su pochi prodotti principali, con una lunga coda di prodotti meno frequenti.




Figura 7 — Distribuzione della variabile “product”

3.2 Analisi bivariata

L'obiettivo dell'analisi bivariata è stato quantificare l'associazione tra ciascuna variabile indipendente e la variabile target "Fraud". Sono stati impiegati test statistici diversi in base alla natura delle variabili.

3.2.1 Variabili numeriche vs. Fraud: Test di Kruskal-Wallis

Il test di Kruskal-Wallis è un test non parametrico che confronta la distribuzione di una variabile numerica tra due o più gruppi (Fraud = 0 vs Fraud = 1), basandosi sui ranghi. Oltre al test stesso, è stato calcolato l'Epsilon Squared (ϵ^2), una misura della dimensione dell'effetto.

Variabile	Statistica H	p-value	Epsilon Squared (ϵ^2)
risk_score	15,68	0,0001	0,0047 (0,47%)
amount	132,80	< 0,0001	0,0424 (4,24%)

Interpretazione: entrambe le variabili mostrano un'associazione statisticamente significativa con "Fraud" (p-value < 0,05). Tuttavia, la dimensione dell'effetto è piccola in entrambi i casi: risk_score spiega solo lo 0,47% della varianza e amount il 4,24%.

3.2.2 Variabili categoriche vs. Fraud: Test del Chi-Quadro

Il test del Chi-Quadro (χ^2) è stato utilizzato per verificare l'indipendenza tra le variabili categoriche e la variabile target. Un valore elevato di χ^2 indica una forte associazione.

Variabile	Statistica χ^2	p-value	Gradi di libertà
status	9.327	< 0,0001	9
product	2.403	< 0,0001	168
paymentmethod	1.277	< 0,0001	12

Interpretazione: tutte e tre le variabili categoriche mostrano un'associazione altamente significativa con "Fraud". La variabile "status" presenta il valore di χ^2 più elevato, seguita da "product" e "paymentmethod".

3.3 Analisi multivariata

L'analisi multivariata è stata condotta attraverso tre diverse mappe di calore di correlazione, ciascuna con un ambito di applicazione specifico.

Mappa di calore di Cramér's V

Cramér's V è una misura di associazione tra variabili categoriche, basata sulla tabella di contingenza e sulla statistica χ^2 , con valori compresi tra 0 (nessuna associazione) e 1 (associazione perfetta). È stata calcolata per le variabili categoriche: paymentmethod, status, product e Fraud.




Figura 8 — Mappa di calore di Cramér's V (variabili categoriche)

Mappa di calore di Pearson

Il coefficiente di Pearson misura la correlazione lineare tra variabili numeriche (e categoriche codificate numericamente tramite label encoding). È appropriato per variabili numeriche continue, in cui il concetto di distanza o scala numerica è ben definito.




Figura 9 — Mappa di calore di Pearson (tutte le variabili codificate)

Mappa di calore di Spearman

La correlazione di Spearman, basata sui ranghi dei dati, è utilizzabile sia per variabili numeriche che categoriche e non richiede l'assunzione di linearità. È stata applicata a tutte le variabili del dataset dopo la codifica.




Figura 10 — Mappa di calore di Spearman (tutte le variabili codificate)

Verifica della significatività con il test di Spearman

Per le variabili numeriche che mostravano una bassa correlazione con “Fraud” nelle mappe di calore, è stato condotto un test formale di Spearman:

Coppia di variabili	Coeff. di Spearman	p-value	Significativa?
Fraud vs. amount	0,207	< 0,0001	Sì
Fraud vs. risk_score	0,071	0,0001	Sì

Entrambe le correlazioni risultano statisticamente significative, confermando l'utilità di mantenere queste variabili nel modello.

Gestione della multicollinearità

L'analisi di Spearman ha evidenziato una forte correlazione tra "status" e "amount" (coefficiente di Spearman = 0,737, p-value < 0,0001). Questa elevata correlazione configura un rischio di multicollinearità.

Decisione: si è scelto di rimuovere la variabile "status" in quanto di minore rilevanza rispetto ad "amount" per l'analisi della frode, e in quanto entrambe avevano mostrato un livello simile di associazione con la variabile target.

3.4 Riepilogo delle variabili dopo la fase esplorativa

Variabile	Ruolo	Motivazione
Fraud	Target	Variabile da predire
amount	Feature	Correlazione significativa con Fraud
risk_score	Feature	Correlazione significativa con Fraud
paymentmethod	Feature	Associazione significativa ($\chi^2 = 1.277$)
product	Feature	Associazione significativa ($\chi^2 = 2.403$)

Variabili rimosse: "fraudmodule" (variabilità quasi nulla) e "status" (multicollinearità con "amount", coeff. Spearman = 0,737).

4. Gestione dello Sbilanciamento delle Classi

Lo sbilanciamento tra la classe 0 (transazioni legittime) e la classe 1 (transazioni fraudolente) costituisce una delle sfide principali di questo progetto. In un dataset con una classe dominante, i modelli tendono a predire quasi sempre la classe maggioritaria, ottenendo un'accuracy elevata ma fallendo nel riconoscere le frodi.

4.1 Strategia: undersampling + SMOTE

Fase 1 — Undersampling della classe maggioritaria: le transazioni con Fraud = 0 sono state sottocampionate al 70%, riducendo il loro numero da circa 3.024 a circa 2.117 osservazioni. Le transazioni fraudolente (85) sono state mantenute integralmente. Il dataset risultante contiene 2.202 righe.

Fase 2 — SMOTE (Synthetic Minority Over-sampling Technique) sul training set: SMOTE genera nuove osservazioni della classe minoritaria interpolando tra osservazioni esistenti. È stato applicato esclusivamente al training set, con un sampling_strategy compreso tra 0,8 e 0,9, al fine di evitare data leakage.

Nota critica sul data leakage: l'applicazione di SMOTE è stata effettuata solo dopo la separazione tra training set e test set, garantendo che nessuna osservazione sintetica influenzasse la valutazione del modello.

La figura seguente mostra la distribuzione della variabile "Fraud" dopo l'undersampling:




Figura 11 — Distribuzione di "Fraud" dopo l'undersampling (prima di SMOTE)

5. Costruzione e Valutazione dei Modelli Predittivi

Dato il ridotto numero di osservazioni e la limitata complessità delle feature, si è scelto di concentrare l'analisi su algoritmi relativamente semplici e interpretabili. Sono stati testati quattro algoritmi.

5.1 Strategia di validazione

Per ciascuno dei 5 split (random state da 1 a 5), il dataset è stato diviso selezionando casualmente 26 osservazioni per ciascuna classe (Fraud = 0 e Fraud = 1) come test set (52 osservazioni totali), mantenendo il resto come training set. Sul training set è stato poi applicato SMOTE. L'accuracy è stata calcolata per ogni split e infine mediata.

5.2 Modelli testati (configurazione iniziale)

5.2.1 Regressione Logistica

Modello lineare di classificazione. Configurazione: C = 0,8, solver LBFGS, class_weight = {0: 1, 1: 2}. Dati normalizzati con StandardScaler.

5.2.2 Decision Tree

Albero decisionale con max_depth = 6 e min_samples_split = 8 per limitare l'overfitting.

5.2.3 Random Forest

Ensemble di 30 alberi, max_depth = 6, min_samples_split = 10.

5.2.4 XGBoost

Gradient boosting: 30 alberi, max_depth = 4, learning_rate = 0,1, subsample = 0,7.

5.3 Risultati della configurazione iniziale

Modello	RS=1	RS=2	RS=3	RS=4	RS=5	Media
Regressione Logistica	69,2%	73,1%	76,9%	82,7%	78,8%	76,2%
Decision Tree	84,6%	88,5%	84,6%	86,5%	92,3%	87,3%
Random Forest	82,7%	90,4%	86,5%	94,2%	92,3%	89,2%
XGBoost	76,9%	90,4%	86,5%	92,3%	96,2%	88,5%

I modelli ad albero superano significativamente la Regressione Logistica. La Random Forest ottiene la migliore accuracy media iniziale (89,2%).

Di seguito le curve ROC rappresentative (split RS=1) per i tre modelli ad albero nella configurazione iniziale:




Figura 12 — Curva ROC — Decision Tree (RS=1, configurazione iniziale)





Figura 13 — Curva ROC — Random Forest (RS=1, configurazione iniziale)



6. Ottimizzazione degli Iperparametri

Per migliorare le performance dei modelli è stata condotta una ricerca sistematica degli iperparametri ottimali tramite Grid Search con cross-validation a 5 fold.

6.1 Metrica di ottimizzazione

Scelta critica: nel contesto del rilevamento frodi, è particolarmente grave classificare una transazione fraudolenta come legittima (falso negativo). Per questo motivo, la metrica scelta per l'ottimizzazione è stata il recall della classe positiva (Fraud = 1).

6.2 Griglie di ricerca

Regression Logistica

Iperparametro	Valori testati
C	0,1 — 0,5 — 0,8 — 1 — 5
fit_intercept	True — False
max_iter	100 — 200 — 300

Decision Tree

Iperparametro	Valori testati
max_depth	8 — 10 — 12 — 14 — 16
min_samples_split	2 — 4 — 8 — 16
criterion	gini — entropy
min_samples_leaf	1 — 2 — 4

Random Forest

Iperparametro	Valori testati
n_estimators	15 — 30 — 50 — 100
max_depth	4 — 6 — 8 — 10 — 12
min_samples_split	6 — 8 — 10 — 14
criterion	gini — entropy
min_samples_leaf	1 — 2 — 4

XGBoost

Iperparametro	Valori testati
n_estimators	15 — 30 — 50 — 100
max_depth	2 — 4 — 8 — 10 — 12
learning_rate	0,01 — 0,05 — 0,1 — 0,2
subsample	0,6 — 0,8 — 1,0
colsample_bytree	0,6 — 0,8 — 1,0
scale_pos_weight	1 — 1,5 — 2

6.3 Risultati dopo l'ottimizzazione

Modello	RS=1	RS=2	RS=3	RS=4	RS=5	Media
Reg. Logistica (tuned)	71,2%	75,0%	78,8%	84,6%	80,8%	78,1%
Decision Tree (tuned)	94,2%	92,3%	92,3%	96,2%	100%	95,0%
Random Forest (tuned)	82,7%	90,4%	90,4%	94,2%	94,2%	90,4%
XGBoost (tuned)	50,0%	50,0%	50,0%	50,0%	50,0%	50,0%

Analisi dei risultati

Decision Tree (tuned) — Modello migliore: con un'accuracy media del 95,0% e un picco del 100% nello split 5, il Decision Tree ottimizzato si dimostra il modello più performante (+8 punti percentuali rispetto alla configurazione iniziale).

Random Forest (tuned): leggero miglioramento rispetto alla versione iniziale (da 89,2% a 90,4%), confermandosi solido e robusto.

Regressione Logistica (tuned): miglioramento marginale (da 76,2% a 78,1%), coerente con la natura lineare del modello.

XGBoost (tuned) — Collasso: dopo l'ottimizzazione, XGBoost si è completamente degradato (accuracy 50% su tutti gli split). Il modello predice esclusivamente la classe 1 per ogni osservazione. Questo è attribuibile alla combinazione della Grid Search ottimizzata per il recall della classe 1 con un'ampia griglia (1.620 combinazioni): l'algoritmo ha trovato una configurazione che massimizza il recall classificando tutto come frode.

Di seguito la curva ROC rappresentativa del Decision Tree ottimizzato (split RS=1):




Figura 14 — Curva ROC — Decision Tree ottimizzato (RS=1)

7. Modello Finale e Interpretabilità

7.1 Modello selezionato: Decision Tree ottimizzato

Il modello selezionato come modello finale è il Decision Tree con iperparametri ottimizzati tramite Grid Search. Questo modello offre il miglior compromesso tra performance predittiva (95,0% di accuracy media) e interpretabilità, un aspetto particolarmente rilevante in ambito fraud detection, dove è importante poter spiegare le ragioni per cui una transazione viene classificata come fraudolenta.

7.2 Feature Importance

L'analisi della feature importance del Decision Tree finale consente di comprendere quali variabili contribuiscono maggiormente alla classificazione. La feature importance misura il contributo relativo di ciascuna variabile nella riduzione dell'impurità (Gini) all'interno dell'albero decisionale.




Figura 15 — Feature Importance del Decision Tree ottimizzato

Il grafico mostra l'ordine di importanza delle variabili utilizzate dall'albero per effettuare le classificazioni, consentendo di identificare i driver principali delle frodi nel dataset.

8. Riepilogo della Pipeline

Fase	Azione	Dettaglio
1. Dati	Unione dataset	Dataset originale + 11 frodi dal dataset aggiuntivo → 4.625 righe
2. Pulizia	Rimozione duplicati	1.516 duplicati rimossi → 3.109 righe, 85 frodi
3. Feature	Rimozione variabili	Rimosse “fraudmodule” e “status”
4. Encoding	Label encoding	Codifica numerica di paymentmethod, product, status
5. Bilanciamento	Undersampling + SMOTE	Undersampling 70% classe 0; SMOTE solo su train set
6. Modellazione	4 algoritmi	LogReg, Decision Tree, Random Forest, XGBoost
7. Validazione	5 split ripetuti	26 obs/classe nel test; accuracy media come metrica
8. Ottimizzazione	Grid Search CV	Recall classe 1 come metrica; 5-fold CV
9. Risultato	Decision Tree tuned	Accuracy media 95,0% — modello selezionato

9. Conclusioni e Considerazioni Finali

Il progetto ha dimostrato la fattibilità di un sistema di rilevamento automatico delle frodi basato su tecniche di Machine Learning, anche in presenza di un dataset di dimensioni relativamente contenute e fortemente sbilanciato.

Il Decision Tree ottimizzato, con un'accuracy media del 95,0% su 5 split di validazione, rappresenta il modello con le migliori performance. La sua natura interpretabile lo rende particolarmente adatto all'impiego in contesti operativi, dove è necessario comprendere e giustificare le decisioni del sistema.

Le principali conclusioni operative sono:

- **Le variabili più rilevanti** per la classificazione delle frodi sono quelle identificate dalla feature importance del modello finale, tra cui "amount", "product", "paymentmethod" e "risk_score".
- **Lo sbilanciamento delle classi** è stato gestito con successo attraverso una combinazione di undersampling e SMOTE, applicato correttamente solo sul training set.
- **L'ottimizzazione degli iperparametri** ha portato un miglioramento significativo per il Decision Tree (+8 punti), ma ha anche evidenziato i rischi di ottimizzazione unidimensionale su dataset piccoli (caso XGBoost).
- **Per sviluppi futuri**, si raccomanda di arricchire il dataset con nuove transazioni per migliorare la robustezza dei modelli, e di esplorare approcci di feature engineering più avanzati.

Fine del report.